RG_PROYECTO_FINAL_DE_AZURE_ESTEBAN_SAENZ

- Proyecto final curso Azure Datapath.
 PF_ESTEBAN_SAENZ_20230827
 Esteban Sáenz V. (esaenz7@gmail.com).

Antecedentes

Este proyecto consiste en un flujo de datos ETL, el cual permite obtener las fuentes de un repositorio local, almacenándolas en la primera capa (bronze) de un datalake. Seguidamente, los datos son unidos en un único conjunto en la segunda capa (silver), para que finalmente sean transformados, preparados - a través de un notebook y un job de spark - y almacenados en la tercera capa (gold). A partir de esta capa los datos pueden ser utilizados como insumos para modelos análiticos, tableros de información, o modelos de IA.

El proyecto tiene como contexto los vuelos domésticos registrados en EEUU durante el año 2018, al cual se adjuntan los registros de eventos meteorológicos y su severidad ocurridos para cada día del año y para cada aeropuerto en particular. Ambos datasets son unidos gracias al conjunto de datos proporcionado por la lista extensa de aeropuertos del repositorio "openflights.org" el cual aporta tanto el código IATA (International Air Transport Association) utilizado coloquialmente para el manejo de vuelos comerciales, como el código oficial ICAO (International Civil Aviation Organization) utilizado para identificar las estaciones de medición meteorológica.

a) Realizar la carga, exploración, análisis, filtrado y limpieza de datos correspondiente para cada dataset.

b) Determinar a partir de la columna de demora en el arribo "arr_delay", el valor de tiempo que permitirá realizar la clasificación binaria entre un vuelo demorado y un vuelo a tiempo.

c) Definir la columna correspondiente para dichas clases. La columna objetivo o "target" se llamará "delayed" y contendrá el valor booleano para las 2 clases posibles de resultados: "demorado" o "a tiempo".

d) Relizar la unión de los datasets a partir de las columnas correspondientes según se detalla con el siguiente pseudocódigo (algunos nombres de columnas son modificados durante la fase de preparación para facilitar su uso):

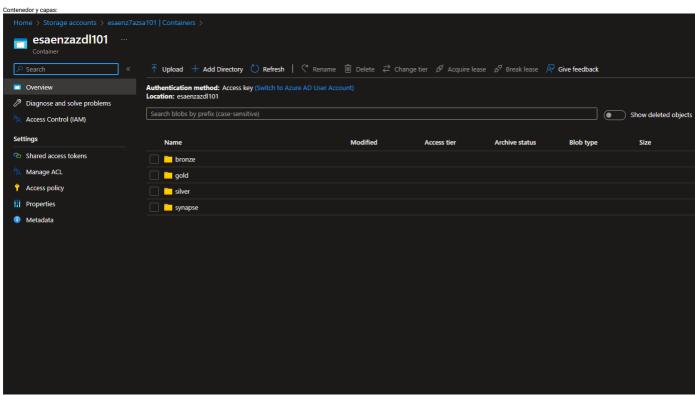
 $data frame -> join (flights.origin == airports.iata) \ data frame -> join (airports.icao == weather.airportcode \& flights.date == weather.date)$

En este caso se realizará la unión de los conjuntos de datos principales de vuelos ('flights') y eventos meterológicos ('weather') por medio de un dataset intermedio con la lista de aeropuertos ('airports'), el cual posee los códigos IATA e ICAO que utilizan respectivamente los datasets principales. Además se incorpora una llave adicional entre fechas, para mantener la relación del vuelo con el evento meteorológico reportado según el día en particular.

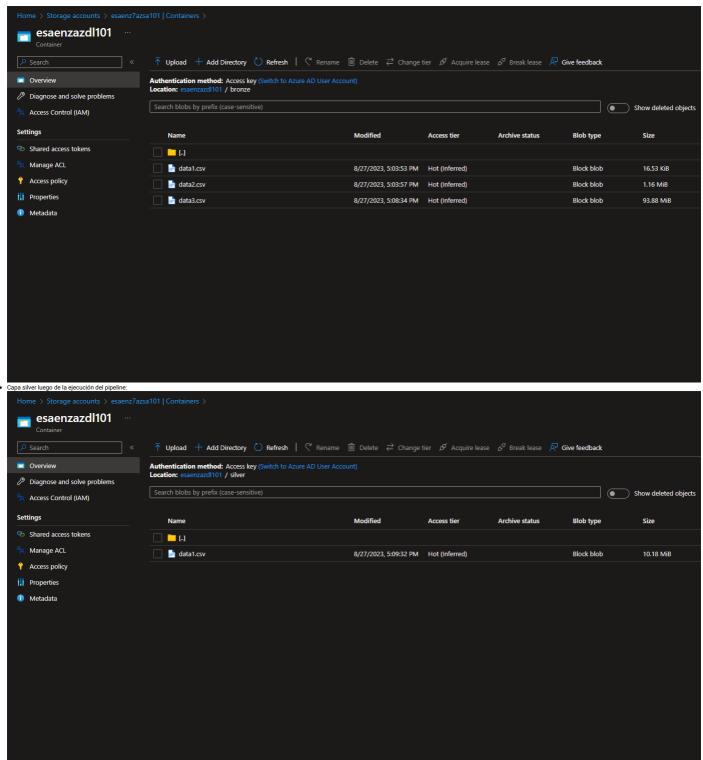
e) Filtrar y preparar las columnas y sub-conjuntos para el proceso de aprendizaje automático.

Arquitectura de datos

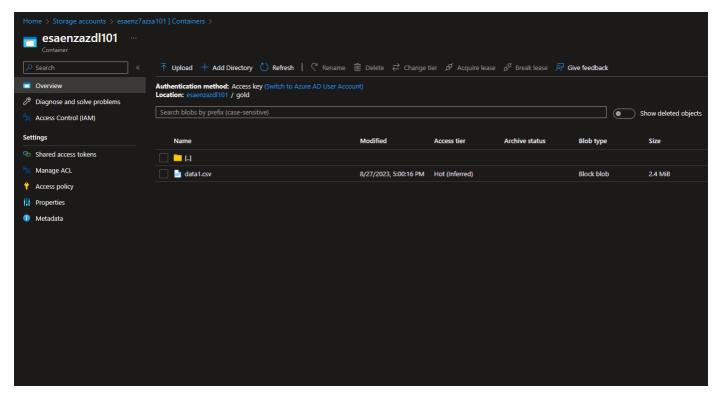
Azure Storage Account



Capa bronze luego de la ejecución del pipeline

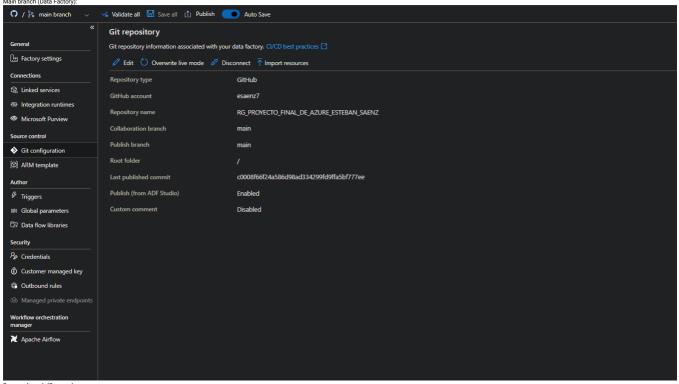


Capa gold luego de la ejecución del pipeline:

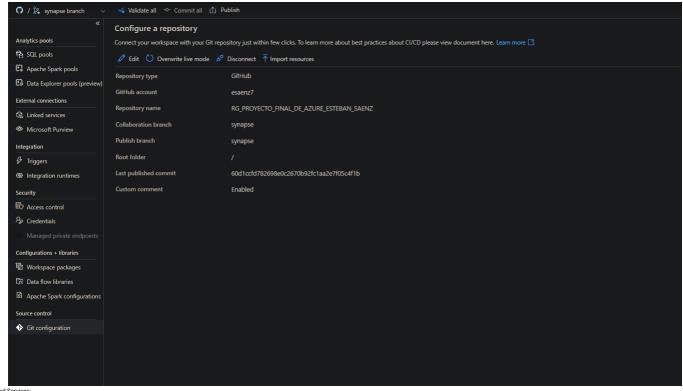


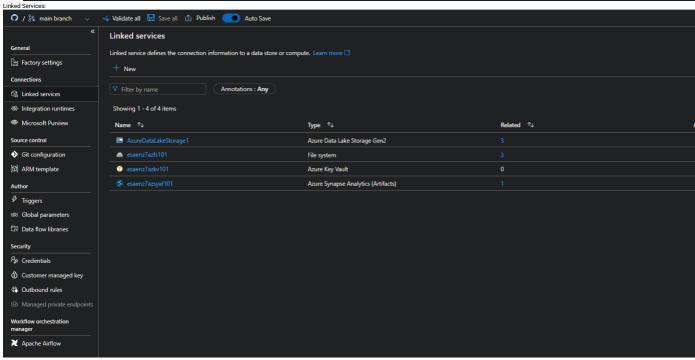
Azude Data Factory

Configuración GIT
 Main branch (Data Factory):

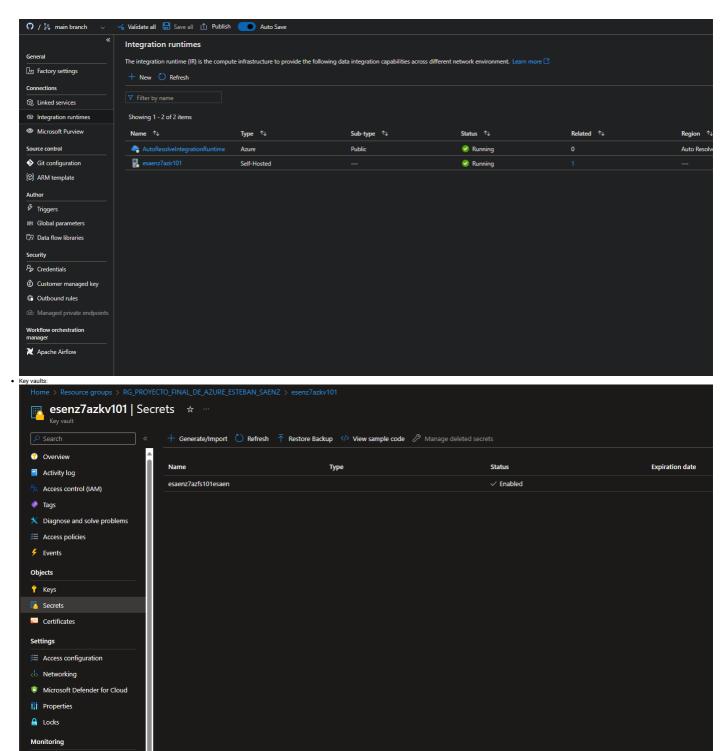


Synapse branch (Synapse):

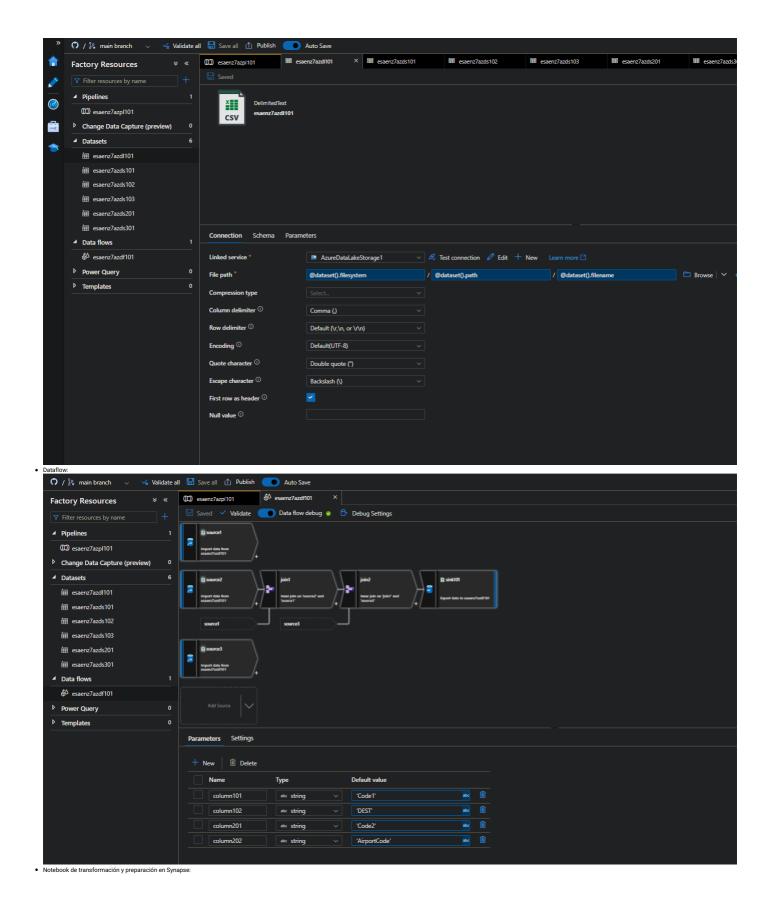


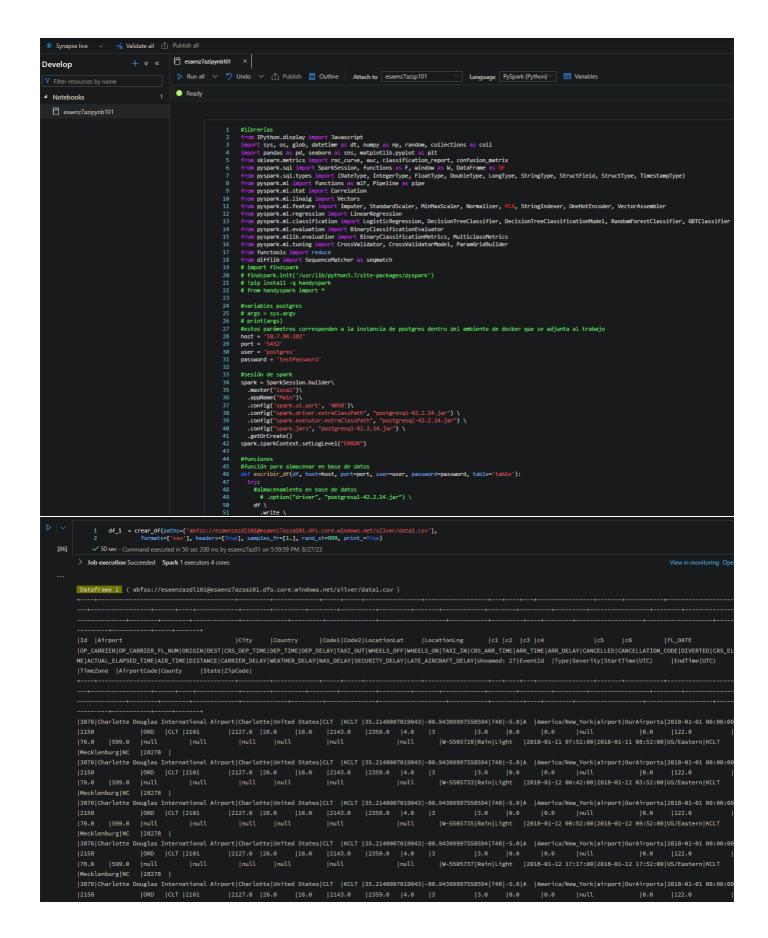


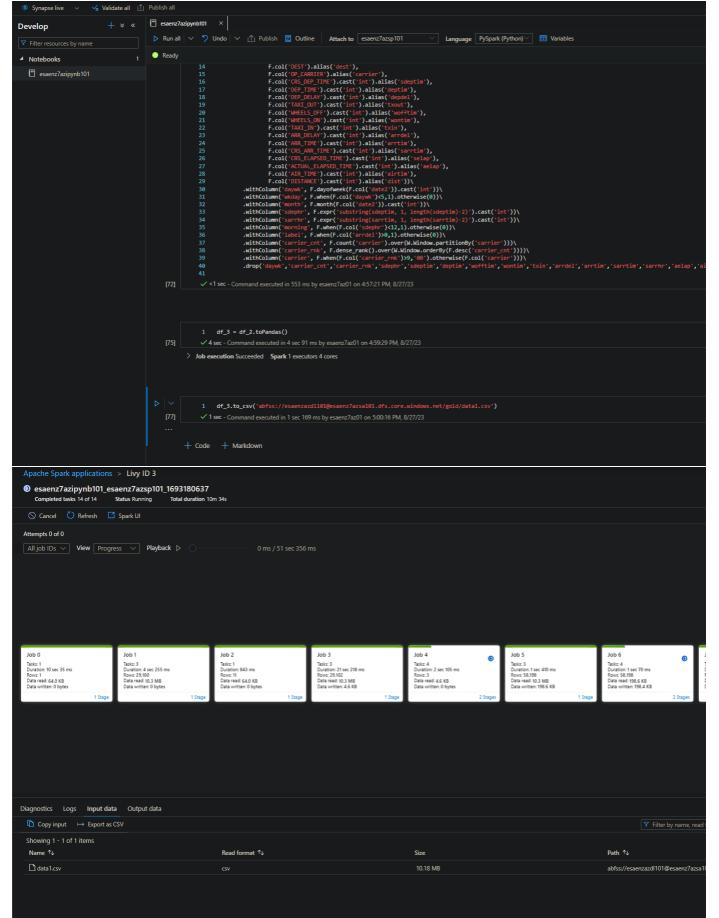
Integration runtime:

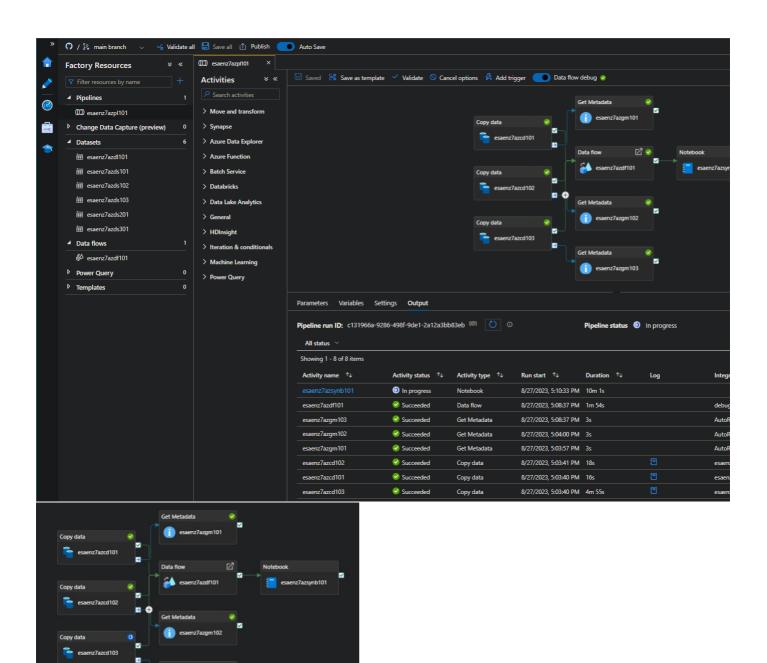


Data sets:

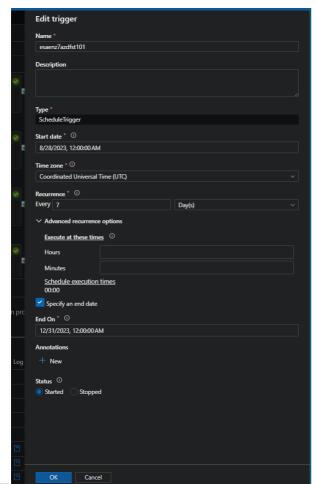








esaenz7azgm103



Triager Vista de las fuentes de datos iniciales (locales):

Reference de datos iniciales (locales):

| FL DATE, OP CARRIER, OP CARRIER, FL NUM, ORTIGIN, DEST, CRS DEP_TIME, DEP_TIME
| 2018-01-01, UA, 249; EWR, DEN, 1517, 1512; 0. 5-5, 0, 15. 0, 1527, 0, 1712; 0, 10-0, 17
| 2018-01-01, UA, 249; EWR, DEN, 1517, 1512; 0. 5-5, 0, 15. 0, 1527, 0, 1712; 0, 10-0, 17
| 2018-01-01, UA, 2426; SMA, DEN, 1335, 1330; 0, 5-5, 0, 15. 0, 1345; 0, 1631; 0, 15-0, 164
| 2018-01-01, UA, 2426; SMA, DEN, 1335, 1330; 0, 5-5, 0, 15, 0, 1345; 0, 1631; 0, 15-0, 164
| 2018-01-01, UA, 2426; MO, DR, 1546, 1552; 0, 6, 0, 19-0, 1611; 0, 1748; 0, 6, 0, 1756
| 2018-01-01, UA, 2424; OND, OMBA, 2241, 2244; 0, 33, 15; 0, 2259; 0, 10, 22, 0, 14, 30,
| 2018-01-01, UA, 2428; DND, OMBA, 2241, 2244; 0, 33, 15; 0, 2259; 0, 10, 22, 0, 14, 30,
| 2018-01-01, UA, 2421; LHH, LAS, 750, 747, 0, 3-0, 14-0, 981; 0, 9826; 0, 10-0, 9922; 93
| 2018-01-01, UA, 2428; DND, CID, 1324; 1318; 0, -60, 110, 1329; 0, 1554; 0, 60, 916; 990
| 2018-01-01, UA, 2418; EMF, EWR, 2224; 2237; 0, 13: 0, 10-0, 2247; 0, 627; 0, 9-0, 638; 0, 2018-01-01, UA, 2416; DNC, EME, 2240; 2235; 0, -5: 0, 9-0, 2244; 0, 624; 0, 7: 0, 647; 6, 2018-01-01, UA, 2415; EWR, PDX, 825; 822; 0, -3: 0, 15: 0, 90; 2244; 0, 162; 0, 80; 0, 231
| 2018-01-01, UA, 2415; EWR, PDX, 825; 822; 0, -3: 0, 15: 0, 937; 0, 1104; 0, 5: 0, 1135; 1, 2018-01-01, UA, 2416; 0, WC, LE, 2069; 2306; 0, 121; 0, 240; 2324; 0, 112; 0, 80; 0, 231
| 2018-01-01, UA, 2415; EWR, PDX, 825; 822; 0, -3: 0, 15: 0, 837; 0, 1104; 0, 5: 0, 1135; 1, 2018-01-01, UA, 2416; CWR, PDX, 825; 822; 0, -3: 0, 15: 0, 937; 0, 1104; 0, 5: 0, 1135; 1, 2018-01-01, UA, 2416; CWR, PDX, 825; 822; 0, -3: 0, 15; 0, 183; 0, 1104; 0, 5: 0, 1135; 0, 131
| 2018-01-01, UA, 2416; EWR, PDX, 825; 822; 0, -3: 0, 15; 0, 140; 0, 130; 0, 5; 0, 15; 0, 133
| 2018-01-01, UA, 2416; EWR, PDX, 825; 822; 0, -3: 0, 15; 0, 140; 0, 130; 0,

Id, irport. City, Country, Codel, Code2, LocationLat, LocationLng, Cl., C2, C3, C1, "Goroka Airport", "Goroka", "Papua New Guinea", "AKA", "AYCA", -6. 0816808 |
1, "Goroka Airport", "Madang", "Papua New Guinea", "MAG", "AYMD", -5. 2070798 |
3, "Mount Hagen Kagamuga Airport", "Mount Hagen", "AR", "AYNZ", -6. 569803, 5, "Port Moresby Jacksons International Airport", "Port Moresby", "Papua New Guinea", "MAG", "AYNZ", -6. 569803, 5, "Port Moresby Jacksons International Airport", "Wewak", "Papua New Guinea", "MAG", "AYNZ", -6. 569803, 5, "Port Moresby Jacksons International Airport", "Wewak", "Papua New Guinea", "MAG", "AYNZ", -6. 569803, 5, "Port Moresby Jacksons International Airport", "Wewak", "Papua New Guinea", "MAG", "AYNZ", -6. 569803, 4, "Wewak International Airport", "Wewak", "Papua New Guinea", "MAG", "AYNZ", -7. 569804, 61. 1604 |
9, "Kangerlussuaq Airport", "Sondrestrom", "Greenland", "SFD", "B6SF", 67. 91 |
9, "Kangerlussuaq Airport", "Sondrestrom", "Greenland", "F5D", "B6SF", 67. 91 |
9, "Kangerlussuaq Airport", "Sondrestrom", "Greenland", "F5D", "B6SF", 67. 91 |
9, "Kangerlussuaq Airport", "Hofn", "Iceland", "AET", "B1AR", 65. 5913091, 21. 22 |
12, "Egilsstaðir Airport", "Hofn", "Iceland", "HFN", "B1HM", 64. 295601, 15. 14, "Hussavik Airport", "Hofn", "Iceland", "HFN", "B1HM", 64. 295601, 15. 14, "Hussavik Airport", "Hussavik", "Iceland", "HFN", "B1HM", 66. 9538097, 17. 42 |
15, "Isaafjorður Airport", "Patreksfjordur", "Iceland", "F57", "B1F8", 66. 19897233 |
19, "Siglufjorður Airport", "Rexkjavik", "Iceland", "KFN", "B1HM", K9997233 |
19, "Siglufjorður Airport", "Rexkjavik", "Iceland", "KFN", "B1HM", K9997233 |
19, "Siglufjorður Airport", "Rexkjavik", "Iceland", "KFN", "B1HM", K9997233 |
19, "Siglufjorður Airport", "Rexkjavik", "Iceland", "KFN", "B1HM", K9997233 |
19, "Siglufjorður Airport", "Rexkjavik", "Iceland", "KFN", "B1HM", K999723 |
19, "Siglufjorður Airport", "Rexkjavik", "Iceland", "KFN", "B1HM", K999723 |
19, "Siglufjorður Airport", "Rexkjavik", "Iceland", "KFN", "B1HMM", K999723 |
19, "Sig

Preview data

Linked service: AzureDataLakeStorage1

Object:

selap dist
122 500
122 599
122 599
122 599
122 599
122 599
122 599
122 599
122 599
122 599
122 599